两层 ReLU 神经网络对连续函数逼近能力的实验验证

1 理论分析

1.1 ReLU 网络的基本表达特点

ReLU 激活函数定义为 ReLU(x)=max(0,x)。它本质上是一个分段线性函数：当 x<0 时输出为 0，当 x≥0 时输出为 x。

单个 ReLU 单元虽然形式简单，但已经具有在某一点发生折转的能力。

对于一维输入，两层 ReLU 神经网络可表示为：

$$N(x) = \sum_{i=1}^{m} a_i ReLU(w_i x + b_i) + c$$

其中，m 为隐藏层神经元个数，a_i、w_i、b_i、c 为网络参数。该式说明，网络输出是若干个 ReLU 基函数的线性组合。由于每个 ReLU 单元都可以在输入空间中引入一个折点，因此多个单元叠加后，网络便能够构造出较复杂的分段线性函数。

1.2 连续函数与分段线性逼近

设函数 f(x)定义在有界闭区间[a,b]上且连续。根据分析学中的基本结论，连续函数在有界闭区间上一致连续。也就是说，对于任意给定的误差ε>0，总能找到足够小的区间划分，使得函数在每个小区间内的变化都足够平缓。

在这种条件下，可以在每个小区间上使用线性函数对原函数进行近似，再把这些线性片段连接起来，就得到一个分段线性函数 g(x)。当区间划分足够细时，可使：

$$sup\{|f(x)-g(x)|, x \in [a,b]\} < \varepsilon$$

这表明定义在有界闭区间上的连续函数，都可以先用分段线性函数进行任意精度的逼近。

1.3 两层 ReLU 网络的逼近结论

前面已经说明，两层 ReLU 网络能够表示分段线性函数；而连续函数又可以被分段线性函数任意精度地逼近。因此，对于定义在有界闭区间上的任意连续函数 f(x)，总存在某个两层 ReLU 神经网络 N(x)，使得：

$$sup\{|f(x)-N(x)|, x \in [a,b]\} < \varepsilon$$

这说明，两层 ReLU 网络具有对连续函数的逼近能力。

1.4 对本文目标函数的适用性分析

函数 $f_1(x)$由多项式函数与正弦函数相加得到，而多项式函数和正弦函数在实数域上都连续，因此 $f_1(x)$在任意有界闭区间上连续。函数 $f_2(x)$由三次多项式项和$e^{-x^2} + sin(5x)$构成。其中指数函数、正弦函数和多项式函数均为连续函数，连续函数的乘积与和仍然连续，因此 $f_2(x)$同样在任意有界闭区间上连续。

所以，这两个函数都满足两层 ReLU 网络逼近的理论条件。与此同时，这两个函数在图像形态上具有一定区分性：$f_1(x)$更突出整体多项式趋势，$f_2(x)$则在局部区域呈现更明显的振荡特征。因此，将二者同时作为实验对象，可以更有针对性地观察两层 ReLU 网络对不同形态连续函数的拟合效果。

2 实验设计

2.1 实验目标

本实验的目标是利用两层 ReLU 神经网络对两个连续函数进行拟合，并从训练损失变化和预测曲线与真实曲线的吻合程度两个方面，分析网络的逼近能力。

2.2 目标函数选取

为了验证这一结论，选取两个具有不同形态特征的连续函数作为研究对象，分别进行建模、训练和拟合分析。两个函数如下：

$$f_1(x) = x^4 - 3x^3 + 2x^2 + sin(3x)$$

$$f_2(x) = x^3 - 2x + e^{-x^2} + sin(5x)$$

其中，函数$f_1(x)$以高阶多项式趋势为主，同时叠加三角函数振荡项；函数$f_2(x)$则包含指数衰减调制下的局部振荡成分，图像形态更具变化性。通过对这两个函数的拟合，可以较全面地观察两层 ReLU 网络对不同类型连续函数的逼近效果。

2.3 数据构造

为了进行函数拟合，分别在给定区间内均匀采样生成训练数据。对于函数 $f_1(x)$，取输入区间为[-2,3]；对于函数 $f_2(x)$，取输入区间为[-3,3]。在各自区间内均匀采样 1000 个

点，并将对应函数值作为监督信号。这种数据构造方式能够较完整地保留目标函数在区间内的变化趋势和局部特征。

2.4 网络结构

实验采用单输入、单输出的前馈神经网络，包含一个隐藏层。网络结构如下：

输入层：1 个节点

隐藏层：256 个神经元

激活函数：ReLU

输出层：1 个节点

该模型属于典型的两层 ReLU 网络，结构简单，但已具备较强的非线性表示能力。

3.5 训练参数设置

实验使用 TensorFlow2 与 Keras 框架实现，损失函数采用均方误差，优化器采用 Adam。主要参数设置如下：

学习率：0.001

训练轮数：1000

损失函数：MSE

优化器：Adam

训练完成后，分别绘制两个函数的损失曲线以及真实函数与预测函数的对比图，用于分析拟合结果。

4 实验实现

实验中，首先定义两个目标函数 $f_1(x)$和 $f_2(x)$，然后分别在对应区间内生成输入样本 x 及目标输出 y。接着构建包含一层 ReLU 隐藏层的神经网络模型，并使用生成的数据对模型进行训练。

在训练过程中，记录每一轮迭代的损失值，以便观察损失是否随训练逐步下降。训练结束后，利用训练好的模型对同一区间内的输入数据进行预测，并将预测曲线与真实曲线绘制在同一张图中进行对比。通过这一过程，可以较直观地判断神经网络对目标函数整体趋势及局部变化的学习情况。

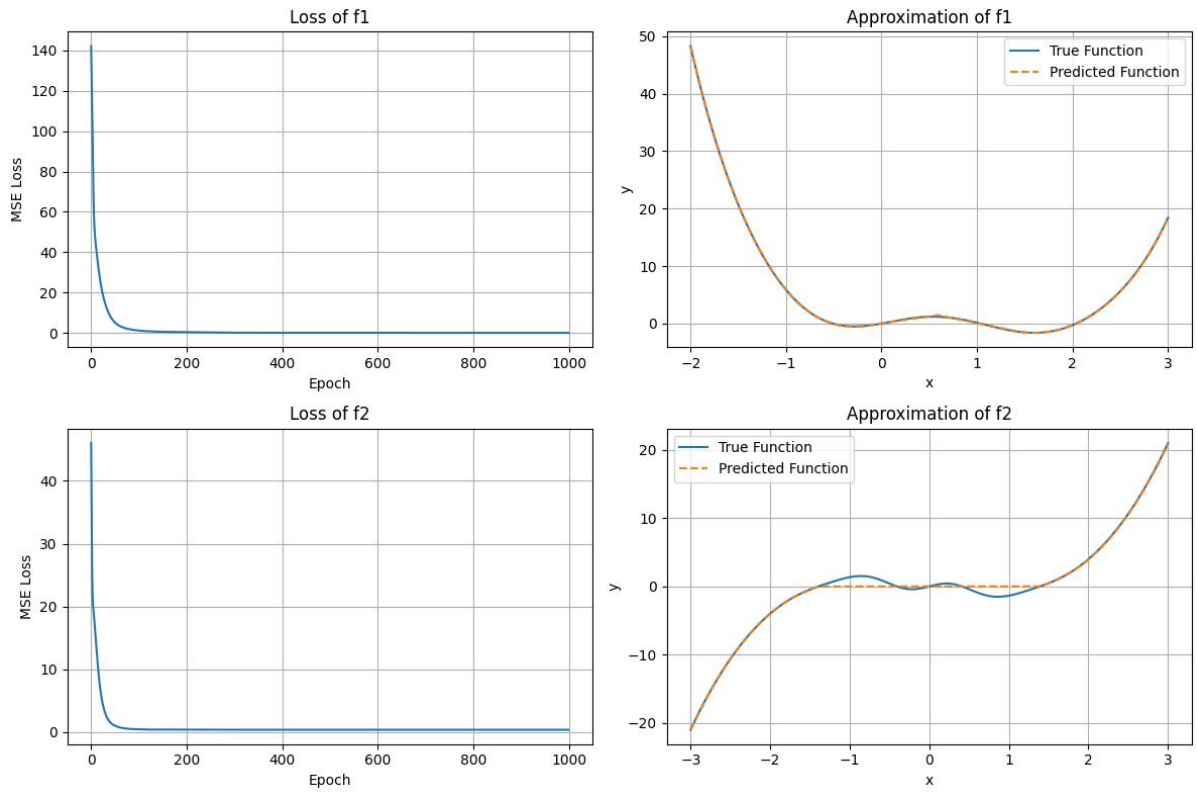

图 1 两个目标函数的损失曲线与拟合结果

5 实验结果与分析

5.1 函数 $f_1(x)$的拟合结果分析

从损失曲线可以看出，函数 $f_1(x)$在训练初期损失较大，但在前几十轮迭代中迅速下降，随后逐渐趋于平稳，最终收敛到较低水平。这表明网络能够较快学习到函数的主要特征。

从拟合结果图来看，预测曲线与真实曲线整体上几乎重合，说明网络已经较好地捕捉了 $f_1(x)$的函数规律。无论是在左侧函数值较大的区域，还是在中间局部波动部分，预测结果都与真实函数保持了较高一致性。

产生这一结果的原因在于，$f_1(x)$虽然包含三角函数项，但整体趋势主要由多项式项决定，函数变化相对连续平滑，局部波动频率也不高，因此较容易被分段线性结构逼近。

5.2 函数 $f_2(x)$的拟合结果分析

对于函数 $f_2(x)$，损失曲线同样在训练初期快速下降，并在后期趋于稳定，说明网络整体上也完成了较有效的学习。

从拟合图可以看出，预测曲线能够较好地跟随真实函数的总体走势，在区间两端以及函数主趋势部分表现较好,仅在中间局部振荡较明显的区域，预测曲线与真实曲线之间存在细微差异。这说明，两层 ReLU 网络对 $f_2(x)$已能实现较好的整体逼近。

6 结论

在理论上，由于连续函数能够被分段线性函数任意精度地逼近，而分段线性函数又可以由两层 ReLU 网络表示，因此可知，两层 ReLU 网络具有对有界闭区间上连续函数的逼近能力。

在实验部分，本文选取了两个不同形态的连续函数，并使用包含单隐藏层的 ReLU 神经网络进行拟合。实验结果表明，网络对两个函数都实现了较好的逼近。其中，函数 $f_1(x)$的拟合效果非常理想；函数 $f_2(x)$也较好地恢复了整体趋势。

综合来看，本实验验证了两层 ReLU 神经网络对连续函数具有较强的逼近能力。